

Laborator 4

Machine Learning - Metode clasice

As. drd. Dan Curavale

Descrierea problemei de clasificare

- Problema este una de **clasificare binara**: vrem sa prezicem **Normal** sau **Atac**.
- Nu clasificam pachete brute din PCAP, ci **instante tabulare** pregatite in Lab 3.
- Fiecare rand descrie o conexiune prin features precum `duration`, `src_bytes`, `dst_bytes`, `protocol_type`, `flag`.
- Intrarea modelului este un vector numeric; iesirea este eticheta conexiunii.

Antrenare supravegheata vs. nesupravegheata


Tip	Ce invata modelul	Exemple in context IDS
Supervised	mapare features -> label din exemple etichetate	clasificare Normal vs Atac (ce facem in Lab 4)
Unsupervised	structura datelor fara etichete (grupuri, anomalii)	clustering sau anomaly detection cand nu avem label-uri curate

- In **Lab 3** am construit exact setup-ul de supervised learning.
- Am pregatit etichete Normal/Atac, am encodat variabilele categoriale, am aplicat scalare unde trebuie si am facut split train/test.
- Fara acesti pasi, modelele din Lab 4 (Tree, Forest, KNN) nu ar fi avut tinta corecta pe care sa o invete.

Metode de clasificare


Decision Tree: cum functioneaza si cand il folosim

- Un arbore pune **intrebari succesive** despre features si imparte datele in ramuri din ce in ce mai specifice.
- La fiecare pas alegem split-ul care separa mai bine clasele;
- Practic, modelul invata atat pragurile $\text{feature} \leq \text{prag}$, cat si ordinea intrebarilor (ce feature apare mai sus), in functie de cat de bine separa clasele.
- Rezultatul este usor de citit: putem urmari drumul de la radacina pana la frunza ca pe un lant de reguli.
- Avantaje: interpretabil, rapid, bun ca baseline si util cand vrem explicatii locale pentru o decizie.
- Il folosim cand vrem un model simplu de explicat si cand regulile decizionale conteaza aproape la fel de mult ca scorul.



Random Forest: de ce este mai robust

- Random Forest este un **ensemble**: antrenam multi arbori pe subseturi diferite de date si features.
- Fiecare arbore vede o perspectiva usor diferita, iar predictia finala este data de **votul majoritar**.
- Mesajul central: un grup de arbori reduce varianata unui arbore individual si generalizeaza mai bine.
- Este de obicei un baseline puternic pentru date tabulare si merge bine cu tuning moderat.




Random Forest: probleme, interventii, hiperparametri

Problema	Cum intervenim	Hiperparametrii
Mai greu de explicat	folosim feature importance si comparatii intre erori	<code>max_features</code>
Cost mai mare de calcul	evitam modele excesiv de mari	<code>n_estimators</code> , <code>max_depth</code>

- In script apar explicit `n_estimators`, `max_depth`, `min_samples_split` si `max_features="sqrt"`.

- KNN nu construiește reguli explicite; etichetează un punct nou după **vecinii cei mai apropiați** din spațiul feature-urilor.
- Aproximarea se măsoară printr-o distanță, în laborator folosind **distanța euclidiană**.
- Parametrul K spune câți vecini consultăm înainte să luăm decizia.
- Avantaje: foarte intuitiv, bun pentru explicații geometrice și util ca model de comparație.
- Il folosim când vrem să vedem cum arată clasificarea bazată pe similaritate locală între instanțe.



Problema	Cum intervenim
Sensibil la scalare Zgomot, outliers, K prea mic Curse of dimensionality, inferenta lenta	standardizare obligatorie alegem K prin validare reducem features inutile


- $K=1$ tinde spre overfitting; un K prea mare “netezeste” excesiv si poate pierde atacurile rare.
- KNN este simplu conceptual, dar fragil in productie daca datele nu sunt bine scalate si curatate.

Metrici de performanta

Matricea de confuzie

Termen	Ce inseamna	Interpretare in IDS
TP	Atac prezis corect ca Atac	atac detectat corect
TN	Normal prezis corect ca Normal	trafic legitim acceptat corect
FP	Normal prezis ca Atac	alarma falsa
FN	Atac prezis ca Normal	atac ratat

- In security, **FN** este de obicei eroarea cea mai periculoasa: atacul trece mai departe fara alerta.
- **FP** nu compromite direct sistemul, dar poate obosi operatorul si poate scadea increderea in alerte.
- Matricea de confuzie spune nu doar *cat* de bine merge modelul, ci si *cum greseste*.



Precision, Recall si F1 in detectarea atacurilor

Metrica	Intrebare	De ce conteaza in IDS
Precision	Cat de curate sunt alertele?	prea mic $\Rightarrow$ multe false positives
Recall	Cate atacuri prindem?	prea mic $\Rightarrow$ multe false negatives
F1-score	Cat de bun este compromisul?	util cand vrem echilibru intre detectie si alarme false

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad \text{F1} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Balanced Accuracy: de ce accuracy simpla nu ajunge

- Accuracy simpla masoara procentul total de predictii corecte, dar poate fi inselatoare pe date dezechilibrate.
- **Balanced Accuracy** trateaza simetric cele doua clase.
- Formula: $\text{Balanced Accuracy} = \frac{TPR + TNR}{2}$, unde $TPR = \frac{TP}{TP + FN}$ si $TNR = \frac{TN}{TN + FP}$.
- **Exemplu numeric** (Pisica = clasa pozitiva): avem 95 caini si 5 pisici; modelul clasifica corect toti cainii si nicio pisica.
- Rezulta: $TP = 0$, $FN = 5$, $TN = 95$, $FP = 0$.
- $\text{Accuracy} = \frac{TP + TN}{100} = \frac{0 + 95}{100} = 0.95 = 95\%$, $TPR = \frac{TP}{TP + FN} = \frac{0}{5} = 0$, $TNR = \frac{TN}{TN + FP} = \frac{95}{95} = 1$,
 $\text{Balanced Accuracy} = \frac{0 + 1}{2} = 0.5 = 50\%$.